지향성 전자파 지도 예측을 위한 RadioMapSeer 기반 교차 도메인 전이학습

[국문 저자명]

[국문 소속]

e-mail : [이메일]

Cross-Domain Transfer Learning from RadioMapSeer for Directional Electromagnetic Field Map Prediction

[Author Names]
[Affiliation]

Abstract

The directional electromagnetic field (EMF) dataset contains limited training samples, motivating additional pretraining on RadioMapSeer. Domain differences, however, make the transferability of learned representations uncertain. We investigate transfer learning using the pretrained image foundation model DINOv2 and a randomly initialized convolutional neural network (CNN). The representative DINOv2 configuration is selected by the lowest validation MAE among the compared configurations. Encoder–decoder transfer with low-rank adaptation and L1 loss in both domains reduces test MAE by 8.0% relative to DINOv2 without additional RadioMapSeer pretraining. In the CNN comparison, source encoder initialization increases test MAE by 3.9%, while SSIM remains similar. Encoder-only transfer also increases MAE in the DINOv2 L1-to-L1 setting. These observations suggest that transfer benefits depend on the transfer scope and adaptation strategy in the evaluated setting.

1. 서론

지향성 전자파(EMF) 지도 예측에는 건물 및 송신기 정보와 안테나 조건을 함께 반영해야 하지만, 다양한 조건의 학습 데이터를 확보하기는 어렵다. 공개 데이터셋 RadioMapSeer[1][2]은 데이터 규모가 커 전이학습에 사용하는 것을 고려할 수 있다. 그러나 RadioMapSeer 데이터셋은 등방 안테나를 가정하고, pathloss map 을 정답으로 사용한다는 차이점이 있다. 두 데이터셋의 특성이 다르기 때문에 전이 학습 시 성능 개선이 이뤄지는지 확인할 필요가 있다.

본 논문은 DINOv2[3] 기반 예측기에서 RadioMapSeer 추가 사전학습의 효과를 분석한다. DINOv2 의 사전학습 가중치에서 시작하여, 추가 사전학습이 없는 경우, 추가 사전학습 후 인코더만 전이한 경우, 그리고 인코더와 디코더 모두 전이한 경우를 비교하여, 모델의 전이 범위 및 학습 방식에 따른 성능 차이를 살펴본다.

또한 소스 인코더 초기화가 일반 영상 사전학습 없이 시작하는 예측기에서도 도움이 되는지 확인하기 위해 CNN 을 보조 비교에 사용하였다. 동일한 데이터 분할, 입력 정보, L1 손실 및 평가 기준에서 무작위 초기화와 소스 인코더 초기화를 비교하였다. 이는 두 모델의 우열을 판단하기 위한 비교가 아니라, CNN 내부에서 소스 인코더 전이의 효과를 확인하기 위한 비교이다.

2. 본론

2.1 공간 정보와 안테나 조건의 표현

모델의 입력은 공간 정보 S, 안테나 패턴 정보 P, 안테나 설정 Q 로 구성된다. 소스 사전학습 시 S 만 입력으로 사용되었고, 타깃 학습 시 P 와 Q 가 입력으로 추가되었다.

S 는 건물 점유 영상, 송신기 Gaussian heatmap(σ=10), log-distance map 으로 구성된다. 점유값은 소스 건물 PNG 가 0 이 아닌 픽셀, 타깃 건물 영상의 B 채널이 0 인 픽셀을 1 로 정의했다.

P 는 Tx 기준 수평 패턴 H, 이미지 중앙 기준으로 하향각을 반영한 수직 패턴 V, Tx 의 beamwidth 를 시각화한 numeric2image (이하 n2i)로 구성된다. 임의의 픽셀 u 의 방위각 θ(u)는 Tx 기준 북쪽 0°, 시계 방향이며, n2i 는 식 (1)을 계산하여 얻는다.

$$n2i(u)=\begin{cases}1, & \left|wrap(\theta(u)-a)\right|\le\dfrac{b}{2}\\ 0, & \text{그외}\end{cases}\quad(1)$$

a 는 안테나 방위각(azimuth), b 는 빔폭(beamwidth)이며 단위는 도(°)이다. wrap 은 상대각을 [−180°,180°)로 변환한다. 송신기와 일치하는 픽셀의 n2i 값은 1 이다.

Q 는 height, downtilt, power, azimuth 정보가 들어간다. Height, downtilt, power 는 학습 데이터 기준으로 min-max scaling 을 적용하여 정규화했다. Azimuth 는 sin 및 cos 함수 값을 입력으로 사용했다.

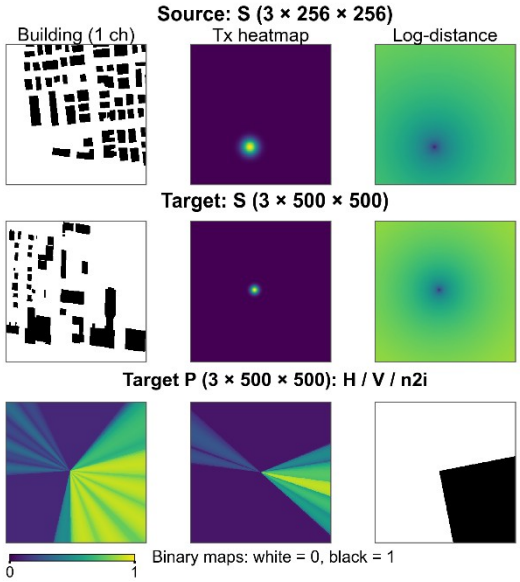


그림 1. 실제 학습 표본의 공간·패턴 입력(패딩 전).

2.2 모델 아키텍처

그림 2 의 DINOv2 ViT-B/14(reg4)[4]는 S 와 P 의 패치 임베딩 합을 입력받는다. 블록 3·6·9·12 에서 CLS token 및 register token 을 제외한 공간 특징을 추출한다.

DPT[5]는 추출한 특징을 256 채널의 4 개 해상도로 재구성하고, Q 를 MLP 로 변환해 식 (2)의 FiLM[6]을 적용한다.

$$\widetilde{F}_i=(1+\gamma_i(Q))\odot F_i+\beta_i(Q)\quad(2)$$

그림 3 의 coarse-to-fine fusion 은 저해상도 특징을 확대해 다음 해상도의 특징과 더하고 잔차 블록으로 보정한다. 최종 출력은 보간 및 crop 을 거쳐 EMF map 이 된다. 타깃 학습 시 학습 안정성을 위해 패턴 임베딩 및 FiLM 출력층은 0 으로 초기화한다.

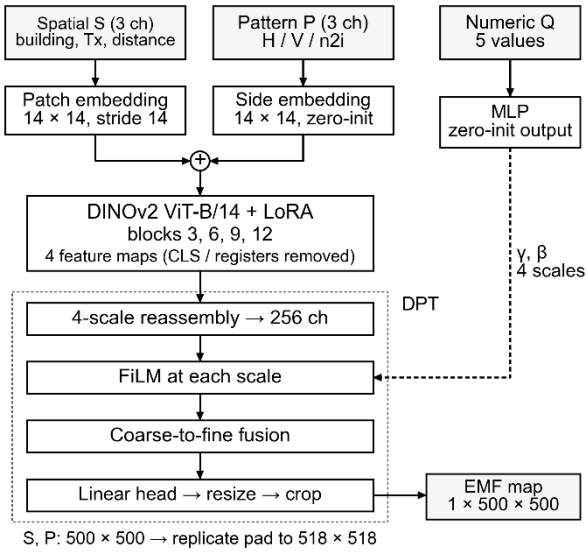


그림 2. 타깃 학습에 사용한 DINOv2 아키텍처. 점선 화살표는 Q 에 의한 FiLM 조건화를 나타낸다.

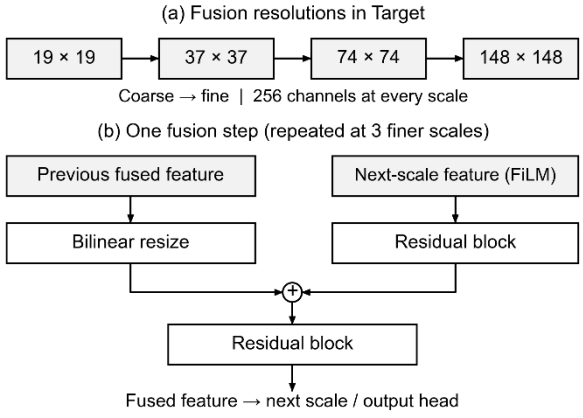


그림 3. Coarse-to-fine fusion 의 해상도 변화와 단계별 연산. 19×19 특징을 잔차 보정한 뒤 시작하며, 이후 세 단계에서 확대, 합산, 보정을 반복한다.

일반 영상 사전학습 없이 시작하는 모델에서 소스 인코더 초기화의 효과를 확인하기 위한 보조 비교에는 CNN 기반 예측기를 사용했다.

CNN 은 채널 수 16·32·64·128 의 인코더와 skip connection 을 갖는 U-Net[7] 계열 디코더로 구성된다. 각 인코더 블록은 3×3 Conv2d, GroupNorm, SiLU 를 두 번 적용하며, 블록 사이에서 max pooling 으로 해상도를 줄인다. 디코더는 bilinear interpolation 으로 특징을 확대한 뒤 같은 해상도의 인코더 특징과 결합한다. 마지막 1×1 Conv2d 는 단일 채널 EMF map 을 출력한다.

P 는 1×1 Conv2d 로 16 채널 특징으로 변환하여 첫 인코더 블록의 출력에 더했다. Q 는 5→32→256 의 MLP 로 변환하고, 병목 특징의 128 개 채널에 FiLM[6]을 적용했다. 조건화는 식 (2)와 같이 계산한다.

F 는 병목 특징이고 γ 와 β 는 Q 에서 생성한 채널별 배율과 편향이다. 패턴 투영층과 FiLM 출력층은 0 으로 초기화했다. 따라서 학습 시작 시 추가 조건화는 공간 특징을 바꾸지 않으며 이후 학습 과정에서 갱신된다. 출력에는 sigmoid 와 clamp 를 적용하지 않았다.

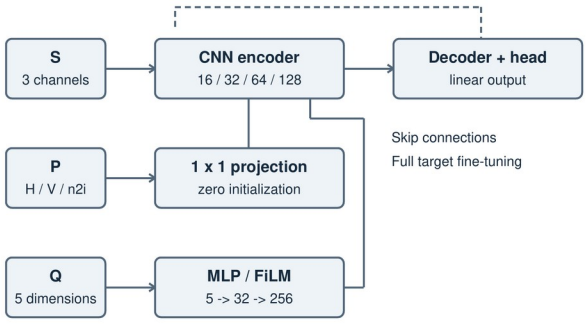


그림 4. 공간·패턴·수치 조건을 결합한 CNN 구조. 소스 인코더만 전이하고 타깃 전체를 학습했다.

2.3 전이 전략과 손실 함수

DINOv2 기반 모델의 소스는 공개 DINOv2 가중치로 초기화한 뒤 전체 모델을 학습했다. 타깃은 추가 소스 학습 없이 시작하는 경우, 소스 인코더만 전이하는 경우, 인코더와 디코더를 함께 전이하는 경우를 비교했다. 앞의 두 경우는 디코더를 새로 초기화해 학습했다.

타깃 인코더의 48 개 선형층에는 LoRA[8]를 적용하고, 패치·패턴 임베딩, LayerNorm, FiLM 도 학습했다. 소스 디코더를 전이한 경우에는 Conv2d 24 개의 LoRA 계층과 1×1 출력층만 학습했다. LoRA 설정은 rank=8, α=16, dropout=0 으로 통일했다.

손실은 건물 내부와 결측 위치를 제외한 유효 픽셀에서 계산했다. L1 loss 와 식 (3)의 L_{M1}을 비교했다. L_S는 Smooth L1 loss(β=0.05), L_M은 MS-SSIM loss[9], L_G는 Sobel filter 기반 Gradient Differential Loss (GDL)이다.

$$L_{M1} = 0.5\,L_S + 0.2\,L_M + 0.3\,L_G \quad (3)$$

MS-SSIM 은 세 스케일을 동일 가중치로 결합하고, GDL 은 수평·수직 Sobel 기울기의 L1 오차로 계산했다. 두 손실은 주변 픽셀 전체가 유효한 위치에만 적용했다.

CNN 기반 모델의 소스는 일반 영상 사전학습 없이 무작위 초기화한 CNN 전체를 학습했다. 타깃은 무작위 초기화하는 경우와 소스 인코더만 전이하는 경우를 비교했다. ENC 도 디코더와 출력층은 새로 초기화했으며, 인코더를 포함한 전체 파라미터를 학습했다.

BASE 와 ENC 의 디코더, 출력층, 패턴 투영층, FiLM 은 동일하게 초기화했다. ENC 는 소스 인코더만 복사한 뒤 전체 모델을 학습했다.

3. 실험

3.1 데이터 구성과 학습 설정

RadioMapSeer DPM/no-cars 의 building map 700 개를 학습·검증·평가용으로 550·50·100 개씩 분할했다. 각 지도에서 Tx 위치 80 개를 사용하므로 표본 수는 각각 44,000·4,000·8,000 개이다. 타깃은 건물 86 개, 표본 768 개로 구성되며, 건물을 68·9·9 개로 분할한 결과 표본 수는 609·78·81 개였다. 동일 건물의 표본은 하나의 분할에만 포함했다.

DINOv2 기반 모델의 소스와 타깃 입력은 replication padding 으로 각각 256×256 에서 266×266, 500×500 에서 518×518 로 확장했다. 예측 결과는 원래 크기로 잘랐으며, 정답은 0~1 범위로 정규화했다.

DINOv2 기반 모델의 소스와 타깃은 배치 크기 32·8 로 각각 최대 50·200 epoch 학습했다.

최적화에는 AdamW[10](weight decay=0)를 사용하고, 모든 학습 대상 파라미터에 동일한 학습률을 적용했다. 학습률은 10^{-6} 에서 10^{-4} 까지 선형 warmup 한 뒤 cosine annealing 으로 10^{-5} 까지 감소하도록 설정했다. Warmup 기간은 소스 5 epoch, 타깃 10 epoch 이다. 검증 MAE 가 각각 15·50 epoch 동안 개선되지 않으면 조기 종료했다.

두 모델 모두 검증 MAE 가 가장 낮은 체크포인트를 선택해 테스트 데이터에서 평가했다. MAE·RMSE·PSNR 은 전체 유효 픽셀로 계산하고, SSIM[11]은 영상별 값을 평균했다.

두 모델은 동일한 데이터 분할과 평가 함수를 사용했다. CNN 의 소스와 타깃 시드는 각각 142·42 로 설정했다. CNN 의 BASE 는 무작위 초기화 모델이며, 모델별 설정 차이는 표 1 과 같다.

표 1. 모델별 실험 구성 차이

항목	DINOv2	CNN
타깃 기준 초기화	공개 사전학습	무작위
소스 배치	32	8
타깃 배치	8	8
주 비교 타깃 시드	42	42
소스 입력 크기	266×266	256×256
타깃 입력 크기	518×518	504×504
패딩	replication	상수 0
타깃 인코더 적응	LoRA 등	전체 미세조정
소스→타깃 손실	L1/M1 조합	L1→L1

CNN 기반 모델도 동일한 최적화·학습률 일정·최대 epoch·조기 종료 설정을 사용했다. 증강·EMA·출력 clipping 은 적용하지 않았다.

3.2 사전학습 및 전이 성능 비교

DINOv2 의 소스 사전학습에서는 MAE·RMSE·PSNR 은 L1, SSIM 은 M1 이 더 좋았다(표 2).

표 2. 소스 사전학습 실험 결과

소스 Loss	Val. MAE	Test MAE	Test RMSE	Test SSIM	Test PSNR
L1	0.0143	0.0151	0.0354	0.9635	29.03
M1	0.0154	0.0161	0.0363	0.9643	28.80

표 3 에서 L1→L1 은 소스와 타깃에 모두 L1 손실을 사용한 구성이다. 대표 구성은 비교한 타깃 구성 중 검증 MAE 가 가장 낮은 인코더·디코더 전이+LoRA 의 L1→L1 로 선택했다(반올림 전 검증 MAE 0.05918). 이 구성은 추가 소스 학습이 없는 타깃 L1 대비 검증·테스트 MAE 를 각각 4.4%, 8.0% 낮췄고 RMSE·PSNR 도 개선했다.

표 3. 타깃 전이학습 실험 결과

소스 Loss	타깃 Loss	Val. MAE	Test MAE	Test RMSE	Test SSIM	Test PSNR
공개 DINOv2 (추가 소스 학습 없음)						
—	L1	0.0619	0.0797	0.1203	0.9062	18.40
—	M1	0.0623	0.0804	0.1236	0.9097	18.16
소스 인코더 전이						
L1	L1	0.0634	0.0819	0.1226	0.9059	18.23
L1	M1	0.0636	0.0791	0.1220	0.9116	18.27
M1	L1	0.0620	0.0778	0.1177	0.9072	18.59
M1	M1	0.0630	0.0772	0.1198	0.9100	18.43
소스 인코더·디코더 전이						
L1	L1	0.0592	0.0733	0.1102	0.9098	19.15
L1	M1	0.0595	0.0727	0.1115	0.9148	19.06
M1	L1	0.0602	0.0760	0.1133	0.9095	18.91
M1	M1	0.0595	0.0742	0.1136	0.9145	18.89

테스트 MAE 와 SSIM 은 인코더·디코더 전이의 L1→M1 에서 가장 좋았으나, 대표 구성은 테스트 지표가 아닌 검증 MAE 를 기준으로 정했다. 인코더 단독 전이는 추가 소스 학습이 없는 동일 타깃 손실 조건보다 검증 MAE 가 모두 증가했고, 테스트 MAE 는 L1→L1 에서만 증가했다. 인코더·디코더 전이+LoRA 는 동일 손실 조합의 인코더 단독 전이보다 모든 보고 지표가 개선됐으며, 검증·테스트 MAE 는 각각 2.8~6.6%, 2.3~10.5% 감소했다.

표 4. 인코더 전이 효과의 보조 비교 (CNN, 타깃 시드 42)

조건	Val. MAE	Test MAE	Test RMSE	Test SSIM	Test PSNR
BASE	0.0602	0.0796	0.1203	0.8998	18.39
ENC	0.0607	0.0828	0.1218	0.9014	18.28

동일한 타깃 시드 42 에서 CNN 의 BASE 와 ENC 의 테스트 MAE 는 각각 0.0796, 0.0828 이었다. 소스 인코더 초기화 후 MAE 는 3.9% 증가했다. RMSE 와 PSNR 은 BASE 가 좋았고, SSIM 은 0.8998 과 0.9014 로 비슷했다. 이 조건에서는 소스 인코더 전이에 따른 픽셀별 예측 오차 감소가 관찰되지 않았다.

3.3 실험 결과 종합 및 논의

DINOv2 의 L1→L1 조건과 CNN 의 보조 비교 모두에서 인코더 전이만으로 테스트 MAE 가 개선되지 않았다. CNN 결과는 일반 영상 사전학습 없이 시작하는 모델에서도 소스 인코더 초기화가 오차 감소를 보장하지 않음을 보여준다. 반면 DINOv2 에서는 인코더·디코더 전이와 LoRA 를 결합한 조건에서 MAE 가 낮아졌다. 이번 결과는 추가 사전학습의 유무뿐 아니라 전이 범위와 적응 방식을 함께 고려할 필요가 있음을 시사한다.

DINOv2 는 공개 사전학습 가중치와 LoRA 를 사용하고 CNN 은 무작위 초기화와 전체 미세조정을 사용했다. 따라서 두 모델의 성능 차이를 아키텍처 또는 전이 범위 하나의 효과로 해석할 수는 없다. 본 비교는 각 모델 내부의 전이 전후 결과를 분석하며, 결론은 단일 소스 초기화와 타깃 시드 42 조건에서 관찰한 결과로 한정한다.

4. 결론 및 향후 연구 방향

본 논문은 지향성 EMF 영상 예측에서 RadioMapSeer 추가 사전학습의 효과를 비교하였다. 검증 MAE 를 기준으로 선택한 인코더·디코더 전이+LoRA 의 L1→L1 구성은 추가 사전학습이 없는 구성보다 테스트 MAE 가 8.0% 낮았다. 데이터셋의 도메인 차이가 있음에도 이 조건에서 개선이 관찰되었다.

CNN 의 보조 비교에서는 소스 인코더 초기화 후 테스트 MAE 가 3.9% 증가했고 SSIM 은 비슷했다. DINOv2 의 L1→L1 인코더 단독 전이에서도 MAE 가 증가했다. 결과는 소스 인코더 초기화만으로 개선이 보장되지 않으며, 관찰된 전이 효과가 전이 범위와 적응 방식에 따라 달라짐을 시사한다. 해석 범위는 제공된 정규화 영상과 비교한 학습 조건으로 한정한다.

이후 연구에서는 추가 사전학습 방식을 기반으로 모델 및 학습 방식을 고도화하여 성능을 높이고자 한다.

참고문헌

[1] Ç. Yapar, R. Levie, G. Kutyniok, and G. Caire, “Dataset of Pathloss and ToA Radio Maps With Localization Application,” arXiv preprint arXiv:2212.11777, 2022.

[2] R. Levie, Ç. Yapar, G. Kutyniok, and G. Caire, “RadioUNet: Fast Radio Map Estimation With Convolutional Neural Networks,” IEEE Transactions on Wireless Communications, vol. 20, no. 6, pp. 4001–4015, Jun. 2021.

[3] M. Oquab et al., “DINOv2: Learning Robust Visual Features without Supervision,” Transactions on Machine Learning Research, Jan. 2024.

[4] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, “Vision Transformers Need Registers,” in Proc. International Conference on Learning Representations (ICLR), 2024.

[5] R. Ranftl, A. Bochkovskiy, and V. Koltun, “Vision Transformers for Dense Prediction,” in Proc. IEEE/CVF International Conference on Computer Vision (ICCV), pp. 12179–12188, Oct. 2021.

[6] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual Reasoning with a General Conditioning Layer,” in Proc. AAAI Conference on Artificial Intelligence, vol. 32, no. 1, pp. 3942–3951, 2018.

[7] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in Proc. MICCAI, LNCS, vol. 9351, pp. 234–241, 2015.

[8] E. J. Hu et al., “LoRA: Low-Rank Adaptation of Large Language Models,” in Proc. International Conference on Learning Representations (ICLR), 2022.

[9] Z. Wang, E. P. Simoncelli, and A. C. Bovik, “Multiscale Structural Similarity for Image Quality Assessment,” in Proc. 37th Asilomar Conference on Signals, Systems and Computers, vol. 2, pp. 1398–1402, Nov. 2003.

[10] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” in Proc. International Conference on Learning Representations (ICLR), 2019.

[11] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600–612, Apr. 2004.