IEIE와 EMF-DINOv2 실험 비교 및 논문 통합 방안

작성일: 2026년 10월 13일

실험 비교 및 논문 통합 계획 보고서 · 추가 연결 실험은 제안 단계

요약

IEIE는 무작위 초기화 대비 인코더 전이 효과를 반복 시드와 데이터 규모로 확인했고, EMF-DINOv2는 일반 영상 사전학습 이후 전이 범위와 적응 조합을 탐색했다. 분할과 평가 규칙이 달라 절대 점수의 직접 순위 비교는 불가능하다. 공통 프로토콜의 연결 실험을 추가하여 통합하거나, 별도 프로토콜의 사례 연구로 구분하여 결합할 수 있다.

주제어: 인코더 전이, DINOv2, 디코더 적응, 실험 비교, 논문 통합

핵심 판단

두 연구는 전파 지도에서 학습한 표현을 지향성 안테나 전자기장 영상 예측에 활용한다는 공통 주제를 갖는다. IEIE는 무작위 초기화 대비 인코더 전이의 효과를 데이터 규모와 반복 시드로 검증하였다. EMF-DINOv2는 일반 영상 사전학습 모델에 전파 지도 학습을 추가하고, 전이 범위와 적응 방식을 바꾸었을 때의 효과를 탐색하였다. 하나의 논문에서는 이를 초기 표현, 전이 범위 및 타깃 적응 방식에 따른 전이 효과라는 연구 질문으로 연결할 수 있다.

현재 절대 MAE를 나란히 놓고 모델 우위를 주장할 수는 없다. 분할, 입력, 학습 손실, 평가 영역 및 집계 규칙이 다르기 때문이다. 기존 결과는 각 프로토콜의 근거로 보존하고, 공통 프로토콜의 연결 실험을 추가하는 통합안을 권한다. 추가 실험 없이 통합하는 경우에는 두 개의 사례 연구로 명확히 구분해야 한다.

비교 범위와 근거 수준

IEIE는 완료된 본 실험과 추가 실험 결과를 대상으로 한다. 본 CNN 실험은 타깃 시드 5개와 소스 시드 3개를 사용하였고, HRFormer 추가 비교는 타깃 시드 3개와 소스 시드 하나를 사용하였다. 추가 비교 항목 152개와 표본 지표 19,152개에 대한 최종 검증이 통과하였다. 여기서 152개는 기존 체크포인트를 재사용한 조건까지 포함한 비교 항목 수이며, 새 학습 152회를 뜻하지 않는다.

팀원 실험은 2026년 10월 12일의 n2i 반영 결과를 주 대상으로 하며, 이전 입력 버전은 변화 분석에만 사용한다. 현재 EMF-DINOv2 폴더에는 코드와 결과 문서는 있지만 문서가 참조하는 save 폴더, 원본 평가 JSON 및 체크포인트는 없다. 따라서 팀원 수치는 문서에 보고된 결과이며, 이번 비교에서 원본 지표 재계산이나 재로드 추론까지 검증한 값은 아니다.

양쪽 모두 PNG/255의 정규화 영상 단위를 평가한다. 절대 전계 강도, 실제 노출 기준 또는 물리 단위의 정확도 개선으로 환산하지 않는다. 소스와 타깃의 지리적 독립성 및 타깃의 물리 단위 역변환은 확인되지 않았다.

연구 질문과 실험 구성

표 1

항목	IEIE	EMF-DINOv2 최신 실험
주 연구 질문	무작위 초기화 대비 소스 인코더 전이 효과	공개 DINOv2 이후 추가 소스 학습과 전이 범위의 효과
백본과 디코더	조건부 소형 U-Net, 추가 HRFormer 비교	DINOv2 ViT-B/14 reg4와 DPT
기준 모델	무작위 초기화	공개 DINOv2 초기화이며 scratch가 아님
소스 학습	DPM 전파 지도, 본 실험 1500회 갱신	DPM 전파 지도, L1과 M1 비교

항목	IEIE	EMF-DINOv2 최신 실험
타깃 적응	인코더 포함 전체 미세조정	인코더 LoRA와 일부 모듈 학습, 디코더 전체 학습 또는 전이·동결·LoRA
전이 범위	인코더만 복사, 디코더와 조건화 새 초기화	인코더만 또는 인코더와 디코더 복사
반복	CNN 타깃 시드 5개, 소스 시드 3개	타깃 시드 42와 소스 시드 142의 단일 실행
주요 추가 분석	데이터 규모, 패턴 정보, 설정 수, 소스 민감도	소스·타깃 손실, 디코더 적응, n2i 입력 버전

두 연구의 BASE를 같은 의미로 사용하면 안 된다. IEIE의 비교는 전파 지도 사전학습과 무작위 초기화 사이의 차이이다. 팀원의 비교는 일반 영상 사전학습을 이미 받은 모델에서 전파 지도 추가 학습의 차이이다. 일반 영상 사전학습과 전파 지도 사전학습 자체의 우열을 분리한 실험은 아니다.

데이터와 평가 규칙의 차이

표 2

항목	IEIE	EMF-DINOv2 최신 실험
타깃 기본 자료	영상 768개, 입력 영상 그룹 86개	영상 768개, 원본 건물 ID 86개
학습·검증·테스트 그룹	60 / 12 / 14	68 / 9 / 9
학습·검증·테스트 영상	534 / 108 / 126	609 / 78 / 81
소스 지도 목록	로컬 701개	지도 0☒699의 700개, 지도 700 제외
공간 입력	B/G가 모두 0인 형상 대리 채널과 위치 픽셀	B채널이 0인 점유 대리 채널, Gaussian, 로그 거리
스칼라	좌표·높이·틸트·전력·주기적 방위각 7개	높이·전력·틸트·주기적 방위각 5개
패턴	수평·수직 각 360개의 1차원 입력	수평·수직 패턴 영상과 n2i 방향 영역
학습 손실	전체 래스터 L1	masked L1 또는 M1 조합
주 MAE	전체 픽셀에서 표본 평균 후 그룹 동일 가중 평균	마스크 유효 픽셀 전체 집계
SSIM	전체 래스터의 영상 SSIM	유효 마스크의 완전한 윈도 지지 영역에서 영상 평균
출력	시그모이드로 제한	선형 출력, 평가 clamp 미사용

팀원 L1은 마스크 기반 L1이고, M1은 0.5×smooth L1(beta=0.05)+0.2×MS-SSIM+0.3×GDL이다. M1의 결과를 SSIM이나 경사 손실 하나의 효과로 해석하지 않는다. n2i는 송신기 위치, 방위각 및 파일명에서 읽은 빔 폭을 이용한 이진 방향 영역이며 실제 물리적 빔 폭의 검증을 뜻하지 않는다.

팀원의 평가 마스크는 원본 입력 B채널로 생성하여 정답이 양수인 위치로 마스크를 만드는 방식과 구분된다. 다만 이를 검증된 실제 실외 영역으로 확정할 수는 없다. 우리 실험이 사용하지 않은 저장 마스크와 팀원의 원본 입력 기반 마스크는 서로 다른 자료이다.

팀원 분할 코드와 우리 목록으로 재구성한 테스트 건물은 23, 29, 31, 59, 68, 78, 81, 88, 100이다. 문서의 건물별 표와 일치하며, 우리 테스트와 공통인 건물은 23 하나이다. 나머지 중 6개는 우리 학습, 2개는 우리 검증에 속한다. 이는 각 실험 내부 누수를 뜻하지 않지만, 기존 우리 모델을 팀원 테스트에 그대로 평가하는 교차 비교가 공정하지 않음을 뜻한다. 원본 팀원 manifest를 확보한 뒤 분할 대응을 다시 확인해야 한다.

따라서 팀원 MAE 0.073340과 우리 CNN 0.072139 또는 HRFormer 0.056937을 비교해 승자를 정할 수 없다. 마스크와 집계 방식이 다르면 같은 예측도 다른 점수를 얻으며, 형상 분할이 달라 평가 난도도 달라진다. 마스크 평가가 더 쉽거나 더 어렵다는 방향도 현재 수치만으로 확정할 수 없다.

관측 결과와 해석

IEIE의 조건부 CNN 인코더 전이는 네 데이터 규모 모두에서 평균 MAE를 낮췄다. 25% 조건의 차이는 사전 지정한 주 평가항목이다. 다른 데이터 규모 및 추가 실험 결과는 해당 설계 범위에 맞춰 보조적으로 해석한다.

표 3

IEIE 조건	무작위 초기화 MAE	인코더 전이 MAE	상대 감소율
CNN 10%	0.092433	0.089948	2.69%
CNN 25%	0.082779	0.079705	3.71%
CNN 50%	0.079228	0.076876	2.97%
CNN 100%	0.073765	0.072139	2.20%
HRFormer 25%	0.071946	0.067238	6.54%
HRFormer 100%	0.062226	0.056937	8.50%

CNN 25%에서 오차 차이의 쌍체 그룹 95% 부트스트랩 구간은 [0.001823, 0.004248]이고, 테스트 그룹 14개 중 13개에서 시드 평균 전이 오차가 낮다. 구간은 고정 분할과 학습 모델에 조건부이며 새로운 지리적 지역에 대한 불확실성을 포함하지 않는다. 전체 패턴 입력은 스칼라 전용 대비 25·50·100%에서 유리했지만 10%에서는 불리하였다. 패턴 효과는 보편적이지 않다.

팀원 최신 실험에서는 검증 MAE로 선택한 대표 조건이 소스 L1과 타깃 L1을 사용하는 인코더·디코더 전이+LoRA이다.

표 4

팀원 최신 조건	검증 MAE	테스트 MAE
공개 DINOv2 직접 적응, 타깃 L1	0.061906	0.079719
인코더만 전이, 소스 L1·타깃 L1	0.063390	0.081929
인코더·디코더 전이+LoRA, 소스 L1·타깃 L1	0.059177	0.073340
인코더·디코더 전이+LoRA, 소스 L1·타깃 M1	0.059516	0.072724

대표 조건은 같은 타깃 L1의 BASE보다 테스트 MAE가 8.00%, 대응 인코더 전용 전이보다 10.48% 낮다. 마지막 행은 테스트 MAE 최저 조건이지만 검증 MAE로 선택한 대표 조건은 아니다. 테스트 순위로 대표 조건을 바꾸지 않는다.

인코더만 전이한 L1→L1은 BASE보다 테스트 MAE가 2.77% 악화하였다. 다른 손실 조합에서는 개선도 있었다. 디코더 전이+LoRA는 대응 인코더 전용 조건 4개 모두에서 개선되었지만 디코더 전이, 동결 및 LoRA가 동시에 달라진다. 따라서 확인한 것은 조합의 효과이며 LoRA만의 인과 효과는 아니다. n2i 추가도 모든 조건에 일관되게 유리하지 않았고, 입력 모듈 크기 변경과 재학습 경로 차이가 함께 존재한다.

팀원 문서의 학습 가능 파라미터는 21,092,737개에서 3,165,761개로 약 85% 감소했으나 최대 CUDA 할당량은 약 10.76 GiB에서 10.83 GiB로 줄지 않았다. 학습 가능 파라미터 감소를 메모리나 실행 시간 감소와 동일시하지 않는다. 우리 합성 배치 메모리 측정과 팀원 학습 로그의 최대 할당량 역시 직접 비교하지 않는다.

하나의 논문으로 연결할 연구 질문

통합 연구 질문은 “안테나 조건부 전자기장 영상 예측에서 전파 지도 사전학습의 효과가 초기 표현, 전이 범위 및 타깃 적응 방식에 따라 어떻게 달라지는가”로 제안한다. 두 연구는 각각 초기화 효과의 반복성과 강한 사전학습 모델의 적응 전략을 설명한다. 기존 FiLM, DPT, DINOv2 또는 LoRA 자체를 새로운 방법으로 주장하지 않는다.

표 5

하위 질문	기존 근거	현재 주장 가능한 범위
전파 지도 인코더가 무작위 초기화보다 유리한가	IEIE CNN와 HRFormer	각 프로토콜의 정규화 영상 전이 효과
일반 영상 사전학습 이후 추가 효과가 있는가	DINOv2 BASE와 인코더 전이	손실·적응 방식에 따른 단일 시드 관측
디코더까지 전이하면 유리한가	DINOv2 인코더 전용과 D_LORA	디코더 전이·동결·LoRA 조합의 효과
데이터가 적을 때 이득이 유지되는가	IEIE 네 데이터 규모	해당 CNN과 분할의 데이터 규모 민감도

하위 질문	기존 근거	현재 주장 가능한 범위
안테나 정보는 항상 유리한가	IEIE 패턴 대조, 팀원 n2i 버전	조건에 의존하는 정보 효과

우리 CNN의 인코더 전이는 유리하고 팀원 특정 인코더 전이는 불리하다는 관측은 모순이 아니다. 기준 표현, 적응 방식 및 평가 과제가 다르다. 어느 차이가 원인인지는 현재 결과만으로 분리할 수 없다. 이를 확정적 메커니즘 설명 대신 통합 연구의 검증 질문으로 둔다.

공통 프로토콜의 연결 실험 제안

이하 실험은 새 제안이며 아직 수행하지 않았다. 이전에 합의한 필수 실험은 완료 상태이다. 통합을 위해 기존 결과를 수정하거나 덮어쓰지 않고 별도의 프로토콜과 출력 경로를 사용한다.

먼저 팀원의 실행별 config, manifest, 학습 로그와 평가 JSON을 확보하여 실제 설정과 보고 결과를 맞춘다. 체크포인트를 확보할 수 있으면 선택된 모델의 재로드 평가와 해시를 확인한다. 이를 확보하지 못하면 팀원 결과는 문서 보고 수준으로 표시한다.

공통 타깃 분할은 점검된 형상 그룹을 사용하여 학습·검증·테스트 ID를 하나로 고정한다. 가장 작은 범위의 제안은 IEIE의 60/12/14 그룹과 전체 학습 규모 534장을 사용하는 것이다. 양쪽을 처음부터 학습하며 타깃 시드 최소 3개를 대응시킨다. 두 팀이 테스트 결과를 이미 확인했으므로 공통 분할이나 새 분할을 맹검 독립 확인이라고 부르지 않는다.

주 연결 비교는 전체 래스터 L1 학습과 그룹 매크로 MAE 평가를 공통으로 사용하는 안이다. 마스크 기반 MAE는 동일 입력 기반 대리 마스크에서 보조적으로 계산한다. SSIM과 RMSE도 같은 구현과 집계 규칙으로 산출한다. 이 변경은 팀원 기존 masked 학습의 재현이 아니라 통합을 위한 새 조건이다. 기존 masked 결과는 별도로 보존한다.

표 6

연결 조건	초기화와 전이	타깃 적응	최소 타깃 실행 수
CNN 기준	무작위 초기화	전체 미세조정	3
CNN 전이	소스 인코더	전체 미세조정	3
DINOv2 기준	공개 사전학습	기존 인코더 LoRA와 새 디코더 학습	3
DINOv2 인코더 전이	추가 소스 인코더	동일 적응 방식	3
DINOv2 디코더 조합	추가 소스 인코더와 디코더	디코더 동결·LoRA와 출력층 학습	3

최소 구성은 타깃 학습 15회이다. 공통 소스 목록은 지도 0⊠699의 700개와 동일한 소스 분할을 제안한다. 소스 손실은 L1로 고정하고 CNN과 DINOv2 각각 최소 한 개의 소스 실행이 필요하므로, 호환되는 기존 소스를 재사용할 수 없다면 소스 학습 최소 2회가 추가된다. 소스 시드 하나의 결과는 소스 반복 안정성을 검증한 것으로 해석하지 않는다. 학습량을 계열별로 다르게 배정한다면 기록하고 백본별 효율 우위를 주장하지 않는다.

양쪽 입력 표현은 우선 각 계열 안에서 고정하여 비교한다. CNN의 1차원 패턴과 DINOv2의 공간 패턴이 다르므로 이 최소 구성은 모델 계열 간 인과적 우위를 분리하지 못한다. 모델 간 성능 순위가 핵심 주장이라면 공통 정보량과 입력 인코딩, 출력 제한, 튜닝 예산 및 계산 예산까지 맞춘 별도 비교가 필요하다.

디코더 조합을 핵심 기여로 삼는다면 “인코더·디코더 전이 후 디코더 전체 학습”을 시드 3개로 추가한다. 이때 타깃 실행은 18회이다. 해당 대조는 디코더 재사용과 이후 적응 조합을 구분하는 데 도움이 되지만 LoRA와 동결의 개별 효과를 완전히 분리하는 것은 아니다. LoRA 단독의 인과 효과를 주장하려면 그에 맞춘 추가 대조가 필요하다.

동일 타깃 시드에서 새 모듈 초기화와 데이터 순서를 가능한 한 대응시키고, 모델 선택은 검증 지표만 사용한다. 학습률 탐색 예산은 각 초기화 비교 쌍에 동일하게 배정한다. 상한 도달·재실행 처리도 양쪽에 같은 규칙으로 고정한다. 기존 테스트 점수로 손실이나 대표 조건을 바꾸지 않는다.

통계는 각 모델 내부의 대응 오차 차이를 주로 보고한다. 그룹과 모델 시드를 구분하고, 고정 분할에서의 그룹 부트스트랩 구간과 시드 변동을 함께 제시한다. 이를 새로운 지역의 일반화 구간으로 해석하지 않는다. 더 강한 독립 확인에는 별도의 미사용 데이터가 필요하다.

추가 실험 없이 통합하는 대안

공통 재학습을 수행하기 어렵다면 두 프로토콜의 사례 연구로 구성할 수 있다. 본문에 데이터와 평가 차이를 먼저 제시하고, 첫 사례에서 IEIE 초기화·데이터 규모 결과를, 둘째 사례에서 DINOv2 전이 범위·적응 결과를 설명한다. 절대 MAE를 하나의 순위 표로 합치거나 서로 다른 개선율을 평균하지 않는다.

이 구성의 장점은 완료된 실험을 바로 활용할 수 있다는 점이다. 한계는 초기 백본과 전이 범위가 함께 달라 효과의 원인을 공통 조건에서 검증하지 못한다는 점이다. 결론은 각 프로토콜에서 관측한 효과와 공통 한계에 한정한다.

논문 구성과 기존 결과의 배치

통합 제목은 “안테나 조건부 전자기장 영상 예측에서 사전학습과 전이 범위의 효과”를 제안한다. 본문은 공통 문제, 데이터 점검, 전이 경로 정의, 공통 연결 실험, 적용 범위 분석 및 한계 순서로 구성한다.

표 7

논문 위치	포함 내용
서론	정답 생성 비용과 전이 효과의 조건 의존성, 두 기준 초기화의 구분
관련 연구	기존 전파 지도 학습, 일반 영상 사전학습, 조건화 및 효율적 적응
데이터와 방법	공통 분할·단위·평가, CNN과 DINOv2 전이 경로, 보존한 기존 프로토콜
주 결과	공통 조건에서 각 계열 내부의 초기화·전이 비교
추가 분석	IEIE 데이터 규모·패턴·설정 수, DINOv2 손실·디코더 조합
부록 후보	HRFormer, n2i 입력 버전, 소스 민감도와 상세 실행 기록
논의와 결론	불리한 전이 조건, 물리·지리적 한계, 단일 소스 시드 및 알려진 테스트의 범위

데이터 효율의 44.87%는 네 관측 점을 사후 보간한 추정이며 실제 확인한 절감률이 아니다. 이를 통합 논문의 주 기여로 내세우려면 별도로 사전 지정한 동일 오차 실험이 필요하다. 기존 결과를 활용할 때에는 기술적 분석으로 둔다.

우선순위와 완료 기준

표 8

순서	작업	완료 기준
1	팀원 원본 결과 확보	실행 설정·분할·지표와 보고 수치 대응
2	통합 주장과 공통 프로토콜 고정	테스트 활용 이력, 입력·손실·평가·시드·선택 예산 명시
3	최소 연결 실험	타깃 5조건×3시드, 필요한 소스 실행, 체크포인트 보존
4	디코더 추가 대조 판단	핵심 주장일 때 전체 학습 대조 3회 추가
5	공통 평가와 검증	표본·그룹 대응, train-only 통계, 선택 체크포인트 재평가
6	통합 원고 작성	공통 결과와 기존 사례의 구분, 부정적 결과 및 한계 유지

권장안은 공통 조건의 연결 실험을 주 근거로 삼고 기존 반복·데이터 규모·적응 분석을 보조 근거로 결합하는 것이다. 실험 예산이 없으면 두 사례 연구로 통합하되 모델 순위와 단일 메커니즘 주장은 보류한다. 기존 연구 자료와 논문은 보존하

고 통합 원고는 별도 버전으로 관리한다.

근거 자료

- IEIE 본 실험 결과 (../runs/main_v1/results.md)

- IEIE 추가 비교 결과 (../runs/followup_v1/results.md)

- IEIE 최종 검증 (../runs/followup_v1/final_audit.json)

- IEIE 평가 데이터 접근 (../data_pipeline.py)

- 팀원 최신 n2i 실험 결과 (https://github.com/CreatePath/EMF-DINOv2/blob/master/docs/experiment_results_n2i_20261012.md)

- 팀원 이전 입력 결과 (https://github.com/CreatePath/EMF-DINOv2/blob/master/docs/experiment_results_20261011.md)

- 팀원 데이터 계약 (https://github.com/CreatePath/EMF-DINOv2/blob/master/docs/data_contract.md)

- 팀원 데이터 로더 (https://github.com/CreatePath/EMF-DINOv2/blob/master/data/radio_maps.py)

- 팀원 지표 집계 (https://github.com/CreatePath/EMF-DINOv2/blob/master/utils/metrics.py)

- 팀원 모델과 전이 범위 (https://github.com/CreatePath/EMF-DINOv2/blob/master/models/transfer_emf.py)

팀원 폴더는 별도 프로젝트이며 보고서 작성 과정에서 수정하지 않았다. GitHub 업로드는 보고서 파일에 한정하며 팀원 소스 저장소를 복사하여 포함하지 않는다.

참고문⊠