III. CNN 기반 조건부 인코더 전이

3.1 비교 목적 및 문제 정의

DINOv2 의 전이 범위 비교에 추가하여, CNN 에서도 Source 인코더 전이의 효과가 나타나는지 검토한다. 동일한 구조와 Target 입력을 사용하는 무작위 초기화 모델(BASE)과 인코더 전이 모델(ENC)을 비교했다. 입력 표현과 데이터 분할은 DINOv2 와 공유하고, 모델별 학습 설정은 구분했다.

모델의 입력은 공간 정보 S, 안테나 패턴 정보 P, 안테나 설정 Q 로 구성된다. S 는 건물 점유 대리 영상, Tx Gaussian heatmap, Tx log-distance map 의 3 채널이다. P 는 수평 패턴 H, 수직 패턴 V, beamwidth 를 영상으로 표현한 n2i 의 3 채널이다. Q 는 height, power, downtilt 와 azimuth 의 sin·cos 값을 포함한다.

좌표와 패턴 영상은 DINOv2 와 같은 전처리 함수로 변환했다. Height, power, downtilt 와 H·V 는 train set 에서 구한 통계로 정규화했다. 정답은 원본 회색조 값을 255 로 나누어 0~1 범위로 변환했다.

3.2 조건부 CNN 구조

CNN 은 채널 수 16·32·64·128 의 인코더와 skip connection 을 갖는 U-Net[1] 계열 디코더로 구성된다. 각 인코더 블록은 3×3 Conv2d, GroupNorm, SiLU 를 두 번 적용하며, 블록 사이에서 max pooling 으로 해상도를 줄인다. 디코더는 bilinear interpolation 으로 특징을 확대한 뒤 같은 해상도의 인코더 특징과 결합한다. 마지막 1×1 Conv2d 는 단일 채널 EMF map 을 출력한다.

P 는 1×1 Conv2d 로 16 채널 특징으로 변환하여 첫 인코더 블록의 출력에 더했다. Q 는 5→32→256 의 MLP 로 변환하고, 병목 특징의 128 개 채널에 FiLM[2]을 적용했다. 조건화는 다음과 같이 계산한다.

$F' = (1 + \gamma(Q)) \odot F + \beta(Q)$.

F 는 병목 특징이고 γ 와 β 는 Q 에서 생성한 채널별 배율과 편향이다. 패턴 투영층과 FiLM 출력층은 0 으로 초기화했다. 따라서 학습 시작 시 추가 조건화는 공간 특징을 바꾸지 않으며 이후 학습 과정에서 갱신된다. 출력에는 sigmoid 와 clamp 를 적용하지 않았다.

3.3 인코더 전이와 대응 초기화

Source 는 일반 영상 사전학습 없이 무작위 초기화한 CNN 전체를 학습했다. Target 은 무작위 초기화하는 경우와 Source 인코더만 전이하는 경우를 비교했다. ENC 도 디코더와 출력층은 새로 초기화했으며, 인코더를 포함한 전체 파라미터를 학습했다.

Source 와 Target 시드는 각각 142·42 로 설정했다. BASE 와 ENC 의 디코더, 출력층, 패턴 투영층, FiLM 은 동일하게 초기화했다. ENC 는 Source 인코더만 복사한 뒤 전체 모델을 학습했다.

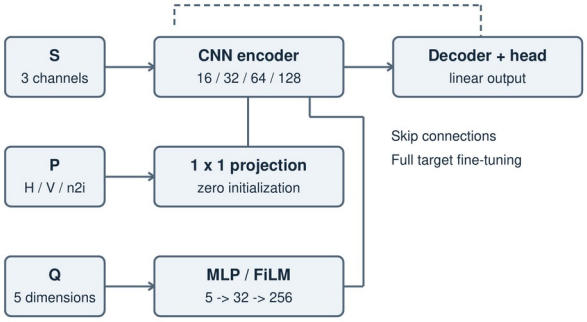


그림 1. 공간·패턴·수치 조건을 결합한 CNN 구조. Source 인코더만 전이하고 Target 전체를 학습했다.

IV. CNN 실험 설정 및 결과

4.1 공통 데이터와 학습 조건

Target 은 건물 영상 그룹을 train·validation·test 68·9·9 개로 분할했고 표본 수는 609·78·81 개이다. Source 는 지도 700 개를 550·50·100 개로 분할하고 지도별 Tx 80 개를 사용했다. 두 모델 계열에 같은 데이터 목록을 적용했으며 Target train set 전체로 학습했다.

손실은 점유 대리 영역과 결측 위치를 제외한 유효 픽셀에서 계산했다. CNN 에는 L1 손실만 사용했으며, 유효 픽셀 수로 나누어 정규화했다.

$L = \Sigma_i M_i |\hat{y}_i - y_i| / \Sigma_i M_i$.

표 1. CNN 재실험의 학습 설정

항목	설정
최적화 / 정밀도	AdamW / FP32
학습률 / 최저 학습률	10^{-4} / 10^{-5} (cosine)
배치 / 누적 / 가중치 감쇠	8 / 1 / 0
기울기 클리핑	최대 노름 5
소스 상한 / 워밍업 / patience	50 / 5 / 15 epoch
타깃 상한 / 워밍업 / patience	200 / 10 / 50 epoch
조기 종료 최소 epoch	소스 10 / 타깃 30
증강 / EMA / 출력 클리핑	모두 미사용

Validation MAE 가 가장 낮은 모델을 선택하여 test set 에서 성능을 측정했다. MAE·RMSE·PSNR 은 전체 유효 픽셀에서 계산하고 SSIM 은 이미지별 값을 평균했다.

4.2 평가 지표와 반복 실험 결과

표 2. CNN 성능 비교 (Target 시드 42)

조건	Val MAE	Test MAE	RMSE	SSIM	PSNR
BASE	0.06016	0.07964	0.12034	0.8998	18.39
ENC	0.06073	0.08277	0.12184	0.9014	18.28

DINOv2 와 동일한 Target 시드 42 에서 BASE 와 ENC 의 test MAE 는 0.079636, 0.082767 였다. 인코더 전이 후 MAE 는 3.93% 증가했다. RMSE 와 PSNR 은 BASE 가 좋았고 SSIM 은 ENC 가 좋았다.

4.3 DINOv2 비교의 해석 범위

DINOv2 의 L1→L1 조건과 CNN 모두 인코더 전이만으로 test MAE 가 개선되지 않았다. DINOv2 에서는 인코더·디코더 전이와 LoRA 를 결합한 조건에서 MAE 가 낮아졌다. 따라서 이번 결과에서는 Source 학습의 적용 자체보다 전이 범위와 적응 방식을 함께 고려할 필요가 있었다. CNN 의 디코더 전이는 비교하지 않았다.

DINOv2 는 공개 사전학습 가중치와 LoRA 를 사용하고 CNN 은 무작위 초기화와 전체 미세조정을 사용했다. 따라서 두 모델의 결과는 초기화와 적응 방식의 차이를 포함하며, 각 모델 내부의 전이 전후 성능을 비교했다.

참고문헌

[1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” arXiv:1505.04597, 2015. https://arxiv.org/abs/1505.04597

[2] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual Reasoning with a General Conditioning Layer,” AAAI, 2018. https://arxiv.org/abs/1709.07871