2. 본론

2.1 공간 정보와 안테나 조건의 표현

본 연구는 RadioMapSeer[1] 소스 과제에서 학습한 지식이 지향성 EMF 지도 예측에 기여하는 조건을 검토한다. DINOv2[2]에서는 전이 범위와 손실 조합을 비교하고, CNN 에서는 동일한 입력 정보와 데이터 분할을 이용해 인코더 전이의 효과를 비교한다.

모델의 입력은 공간 정보 S, 안테나 패턴 정보 P, 안테나 설정 Q 로 구성된다. Source 사전학습 시 S 만 입력으로 사용되었고, Target 학습 시 P 와 Q 가 입력으로 추가되었다.

S 는 building map(건물=1, 실외=0), Tx Gaussian heatmap (σ=10), Tx log-distance map 으로 구성된다.

P 는 Tx 기준 수평 패턴 H, 이미지 중앙 기준으로 하향각을 반영한 수직 패턴 V, Tx 의 beamwidth 를 시각화한 numeric2image (이하 n2i)로 구성된다. 임의의 픽셀 u 의 방위각 θ(u)는 Tx 기준 북쪽 0°, 시계 방향이며, n2i 는 식 (1)을 계산하여 얻는다.

$$n2i(u)=\begin{cases}1, & \text{¿}wrap(\theta(u)-a)\vee\leq\frac{b}{2} \\ 0, & \text{그외}\end{cases} \quad (1)$$

wrap 은 상대각을 [–180°,180°)로 변환한다. Tx 와 일치하는 픽셀은 1 이다.

Q 는 height, downtilt, power, azimuth 정보가 들어간다. Height, downtilt, power 는 train set 기준으로 min-max scaling 을 적용하여 정규화했다. Azimuth 는 sin 및 cos 함수 값을 입력으로 사용했다.

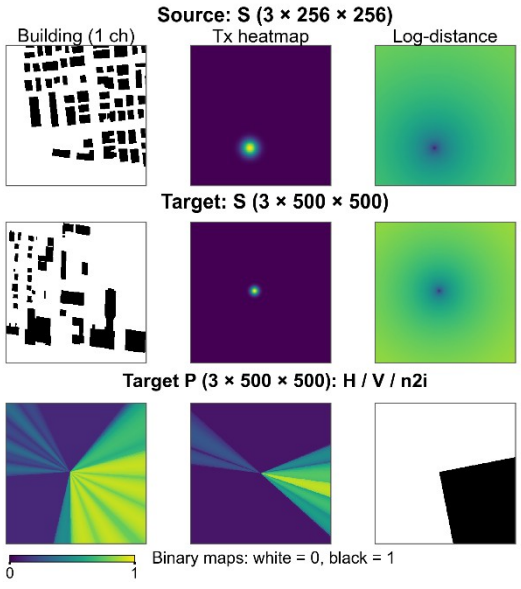


그림 1. 실제 학습 표본의 공간·패턴 입력(패딩 전).

2.2 DINOv2 기반 예측 모델 2.2 모델 아키텍처

그림 2 의 DINOv2 ViT-B/14(reg4)[3]는 S 와 P 의 패치 임베딩 합을 입력받는다. 블록 3·6·9·12 에서 CLS token 및 register token 을 제외한 공간 특징을 추출한다.

DPT[4]는 추출한 특징을 256 채널의 4 개 해상도로 재구성하고, Q 를 MLP 로 변환해 식 (2)의 FiLM[5]을 적용한다.

$$\tilde{F}_i=(1+\gamma_i(Q))\odot F_i+\beta_i(Q) \quad (2)$$

그림 3 의 coarse-to-fine fusion 은 저해상도 특징을 확대해 다음 해상도의 특징과 더하고 잔차 블록으로 보정한다. 최종 출력은 보간 및 crop 을 거쳐 EMF map 이 된다. 사후 학습 시 학습 안정성을 위해 패턴 임베딩 및 FiLM 출력층은 0 으로 초기화한다.

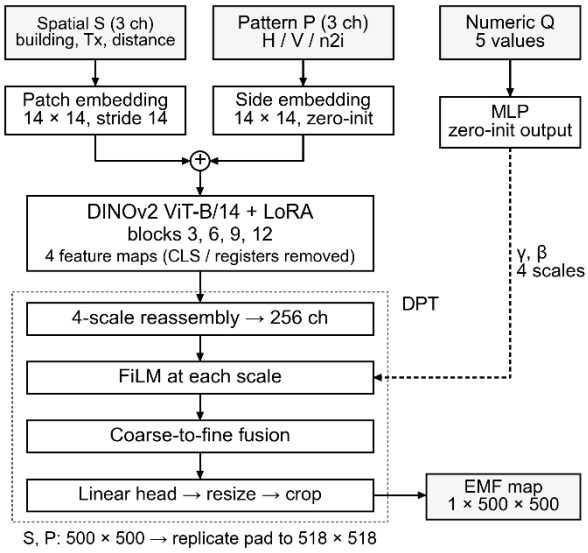


그림 2. Target 학습에 사용한 DINOv2 아키텍처. 점선 화살표는 Q 에 의한 FiLM 조건화를 나타낸다.

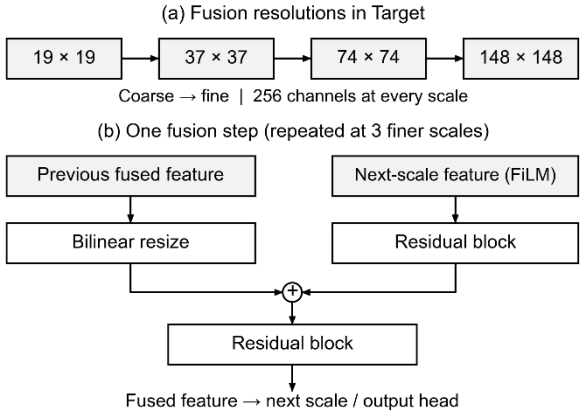


그림 3. Coarse-to-fine fusion 의 해상도 변화와 단계별 연산. 19×19 특징을 잔차 보정한 뒤 시작하며, 이후 세 단계에서 확대,

합산, 보정을 반복한다.

2.3 전이 전략과 손실 함수

Source 는 공개 DINOv2 가중치로 초기화한 뒤 전체 모델을 학습했다. Target 은 추가 Source 학습 없이 시작하는 경우, Source 인코더만 전이하는 경우, 인코더와 디코더를 함께 전이하는 경우를 비교했다. 앞의 두 경우는 디코더를 새로 초기화해 학습했다.

Target 인코더의 48 개 선형층에는 LoRA[6]를 적용하고, 패치·패턴 임베딩, LayerNorm, FiLM 도 학습했다. Source 디코더를 전이한 경우에는 Conv2d 24 개의 LoRA 계층과 1×1 출력층만 학습했다. LoRA 설정은 rank=8, α=16, dropout=0 으로 통일했다.

손실은 건물 내부와 결측 위치를 제외한 유효 픽셀에서 계산했다. L1 loss 와 식 (3)의 L_{M1}을 비교했다. L_S는 Smooth L1 loss(β=0.05), L_M은 MS-SSIM loss[7], L_G는 Sobel filter 기반 Gradient Differential Loss (GDL)이다.

$$L_{M1}=0.5L_S+0.2L_M+0.3L_G \quad (3)$$

MS-SSIM 은 세 스케일을 동일 가중치로 결합하고, GDL 은 수평·수직 Sobel 기울기의 L1 오차로 계산했다. 두 손실은 주변 픽셀 전체가 유효한 위치에만 적용했다.

2.4 CNN 기반 조건부 인코더 전이

DINOv2 의 전이 범위 비교에 추가하여 CNN 에서도 인코더 전이의 효과가 나타나는지 검토했다. CNN 은 2.1 절과 동일한 S·P·Q 를 입력받는다. 동일 구조에서 무작위 초기화와 Source 인코더 초기화를 비교했으며, 디코더 전이와 손실 조합은 DINOv2 실험에서 다뤘다.

CNN 은 채널 수 16·32·64·128 의 인코더와 skip connection 을 갖는 U-Net[10] 계열 디코더로 구성된다. 각 인코더 블록은 3×3 Conv2d, GroupNorm, SiLU 를 두 번 적용하며, 블록 사이에서 max pooling 으로 해상도를 줄인다. 디코더는 bilinear interpolation 으로 특징을 확대한 뒤 같은 해상도의 인코더 특징과 결합한다. 마지막 1×1 Conv2d 는 단일 채널 EMF map 을 출력한다.

P 는 1×1 Conv2d 로 16 채널 특징으로 변환하여 첫 인코더 블록의 출력에 더했다. Q 는 5→32→256 의 MLP 로 변환하고, 병목 특징의 128 개 채널에 FiLM[5]을 적용했다. 조건화는 식 (2)와 같이 계산한다.

F 는 병목 특징이고 γ 와 β 는 Q 에서 생성한 채널별 배율과 편향이다. 패턴 투영층과 FiLM 출력층은 0 으로 초기화했다. 따라서 학습 시작 시 추가 조건화는 공간 특징을 바꾸지 않으며 이후 학습 과정에서 갱신된다. 출력에는 sigmoid 와 clamp 를 적용하지 않았다.

대응 초기화 및 소스 전이

Source 는 일반 영상 사전학습 없이 무작위 초기화한 CNN 전체를 학습했다. Target 은 무작위 초기화하는 경우와 Source 인코더만 전이하는 경우를 비교했다. ENC 도 디코더와 출력층은 새로 초기화했으며, 인코더를 포함한 전체 파라미터를 학습했다.

Source 와 Target 시드는 각각 142·42 로 설정했다. BASE 와 ENC 의 디코더, 출력층, 패턴 투영층, FiLM 은 동일하게 초기화했다. ENC 는 Source 인코더만 복사한 뒤 전체 모델을 학습했다.

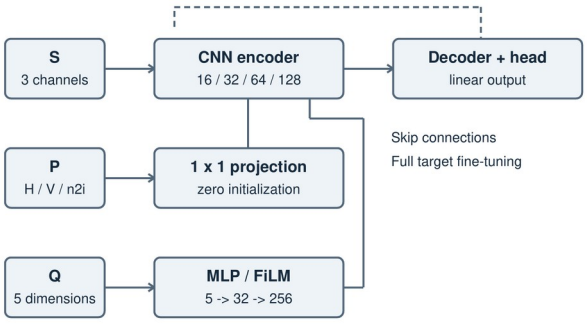


그림 4. 공간·패턴·수치 조건을 결합한 CNN 구조. Source 인코더만 전이하고 Target 전체를 학습했다.

3. 구현

3.1 데이터 구성과 학습 설정

RadioMapSeer DPM/no-cars 의 building map 700 개를 학습·검증·평가용으로 550·50·100 개씩 분할했다. 각 지도에서 Tx 위치 80 개를 사용하므로 표본 수는 각각 44,000·4,000·8,000 개이다. Target 은 건물 86 개, 표본 768 개로 구성되며, 건물을 68·9·9 개로 분할한 결과 표본 수는 609·78·81 개였다. 동일 건물의 표본은 하나의 분할에만 포함했다.

DINOv2 실험에서 Source 와 Target 입력은 replication padding 으로 각각 256×256 에서 266×266, 500×500 에서 518×518 로 확장했다. 예측 결과는 원래 크기로 잘랐으며, 정답은 0~1 범위로 정규화했다.

DINOv2 실험에서 Source와 Target은 배치 크기 32·8로 각각 최대 50·200 epoch 학습했다.

최적화에는 AdamW[8](weight decay=0)를 사용하고, 모든 학습 대상 파라미터에 동일한 학습률을 적용했다. 학습률은 10^{-6}에서 10^{-4}까지 선형 warmup 한 뒤 cosine annealing으로 10^{-5}까지 감소하도록 설정했다. Warmup 기간은 Source 5 epoch, Target 10 epoch이다. 검증 MAE가 각각 15·50 epoch 동안 개선되지 않으면 조기 종료했다.

검증 MAE가 가장 낮은 모델을 선택해 평가용 데이터에서 성능을 측정했다. MAE·RMSE·PSNR은 전체 유효 픽셀로 계산하고, SSIM[9]은 이미지별 값을 평균했다.

3.2 DINOv2 사전학습 및 전이 성능 비교

Source 사전학습에서는 MAE·RMSE·PSNR은 L1, SSIM은 M1이 더 좋았다(표 1).

표 1. Source 사전학습 실험 결과

Source Loss	Validation MAE	Test MAE	Test RMSE	Test SSIM	Test PSNR
L1	**0.01429**	**0.01506**	**0.03537**	0.9635	**29.03**
M1	0.01536	0.01613	0.03632	**0.9643**	28.80

표 2에서 L1 → L1은 Source와 Target에 모두 L1 손실을 사용한 조건이다. 이 조건의 인코더·디코더 전이+LoRA 조합은 추가 Source 학습이 없는 Target L1 대비 검증·평가 MAE를 각각 4.408%, 8.002% 낮추고 RMSE·PSNR도 개선했다.

표 2. Target 전이학습 실험 결과

Source Loss	Target Loss	Validation MAE	Test MAE	Test RMSE	Test SSIM	Test PSNR
공개 DINOv2 (추가 Source 학습 없음)						
—	L1	0.06191	0.07972	0.1203	0.9062	18.40
—	M1	0.06228	0.08042	0.1236	0.9097	18.16
Source 인코더 전이						
L1	L1	0.06339	0.08193	0.1226	0.9059	18.23
L1	M1	0.06357	0.07914	0.1220	0.9116	18.27
M1	L1	0.06197	0.07779	0.1177	0.9072	18.59
M1	M1	0.06295	0.07722	0.1198	0.9100	18.43
Source 인코더·디코더 전이						
L1	L1	**0.05918**	0.07334	**0.1102**	0.9098	**19.15**
L1	M1	0.05952	**0.07272**	0.1115	**0.9148**	19.06
M1	L1	0.06025	0.07597	0.1133	0.9095	18.91
M1	M1	0.05951	0.07421	0.1136	0.9145	18.89

평가 MAE와 SSIM은 인코더·디코더 전이의 L1 → M1에서 가장 좋았다. 인코더 전이는 추가 Source 학습이 없는 동일 Target 손실 조건보다 검증 MAE가 모두 증가했고, 평가 MAE는 L1 → L1에서만 증가했다. 인코더·디코더 전이+LoRA 조합은 동일 손실 조합의 인코더 전이보다 모든 보고 지표를 개선했으며, 검증·평가 MAE를 각각 2.773~6.645%, 2.339~10.48% 낮췄다.

3.3 CNN 인코더 전이 성능 비교

CNN은 3.1절과 동일한 데이터 분할과 평가 함수를 사용했다. Source와 Target 시드는 각각 142·42로 설정했다. CNN의 BASE는 무작위 초기화 모델이며, 모델별 설정 차이는 표 3과 같다.

표 3. 모델별 실험 구성 차이

항목	DINOv2	CNN
타깃 기준 초기화	공개 사전학습	무작위
Source 배치	32	8
Target 배치	8	8
주 비교 Target 시드	42	42
Source 입력 크기	266×266	256×256
Target 입력 크기	518×518	504×504
패딩	replication	상수 0
Target 인코더 적응	LoRA 등	전체 미세조정
Source→Target 손실	L1/M1 조합	L1→L1

최적화는 AdamW와 cosine schedule을 사용했다. 학습률, warmup, 최대 epoch, 조기 종료 대기 기간은 3.1절과 동일하게 설정했다. 증강·EMA·출력 clipping은 적용하지 않았다. Validation MAE가 가장 낮은 모델을 선택하여 test set에서 성능을 측정했다.

표 4. CNN 성능 비교 (Target 시드 42)

조건	Val MAE	Test MAE	RMSE	SSIM	PSNR
BASE	0.06016	0.07964	0.12034	0.8998	18.39
ENC	0.06073	0.08277	0.12184	0.9014	18.28

DINOv2와 동일한 Target 시드 42에서 BASE와 ENC의 test MAE는 0.079636, 0.082767였다. 인코더 전이 후 MAE는 3.93% 증가했다. RMSE와 PSNR은 BASE가 좋았고 SSIM은 ENC가 좋았다.

3.4 실험 결과 종합 및 논의

DINOv2의 L1→L1 조건과 CNN 모두 인코더 전이만으로 test MAE가 개선되지 않았다. DINOv2에서는 인코더·디코더 전이와 LoRA를 결합한 조건에서 MAE가 낮아졌다. 따라서 이번 결과에서는 Source 학습의 적용 자체보다 전이

범위와 적응 방식을 함께 고려할 필요가 있었다. CNN 의 디코더 전이는 비교하지 않았다.

DINOv2 는 공개 사전학습 가중치와 LoRA 를 사용하고 CNN 은 무작위 초기화와 전체 미세조정을 사용했다. 따라서 두 모델의 결과는 초기화와 적응 방식의 차이를 포함하며, 각 모델 내부의 전이 전후 성능을 비교했다.

참고문헌

[1] Ç. Yapar, R. Levie, G. Kutyniok, and G. Caire, “Dataset of Pathloss and ToA Radio Maps With Localization Application,” arXiv preprint arXiv:2212.11777, 2022.

[2] M. Oquab et al., “DINOv2: Learning Robust Visual Features without Supervision,” Transactions on Machine Learning Research, Jan. 2024.

[3] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, “Vision Transformers Need Registers,” in Proc. International Conference on Learning Representations (ICLR), 2024.

[4] R. Ranftl, A. Bochkovskiy, and V. Koltun, “Vision Transformers for Dense Prediction,” in Proc. IEEE/CVF International Conference on Computer Vision (ICCV), pp. 12179–12188, Oct. 2021.

[5] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual Reasoning with a General Conditioning Layer,” in Proc. AAAI Conference on Artificial Intelligence, vol. 32, no. 1, pp. 3942–3951, 2018.

[6] E. J. Hu et al., “LoRA: Low-Rank Adaptation of Large Language Models,” in Proc. International Conference on Learning Representations (ICLR), 2022.

[7] Z. Wang, E. P. Simoncelli, and A. C. Bovik, “Multiscale Structural Similarity for Image Quality Assessment,” in Proc. 37th Asilomar Conference on Signals, Systems and Computers, vol. 2, pp. 1398–1402, Nov. 2003.

[8] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” in Proc. International Conference on Learning Representations (ICLR), 2019.

[9] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600–612, Apr. 2004.

[10] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” arXiv:1505.04597, 2015.